

Anexo II

Análisis exploratorio de datos (EDA)

FairNight: un sistema de recomendación de precios para anuncios de Airbnb

Trabajo Fin de Máster, Modalidad Semipresencial
Yago Coll Crespo, Septiembre 2026

Análisis exploratorio de datos: el recorrido completo sobre Barcelona

Este anexo desarrolla en detalle el análisis exploratorio resumido en la Sección 2 de la memoria: carga y tipado, tratamiento de nulos y duplicados, análisis univariante y bivalente de cada variable, correlaciones, geografía y amenities. **Todo el recorrido está construido sobre el notebook 01_eda.ipynb de Barcelona**, tomada como referencia por ser la ciudad con el proceso más documentado. Las otras 6 ciudades parten del mismo fichero (`listings.csv.gz` de Inside Airbnb, 90 columnas) y siguen el mismo criterio, pero cada una tiene su propio recorrido completo, con sus propios hallazgos y particularidades: la última sección de este anexo (M) recoge, ciudad a ciudad, en qué se aparta cada una de lo descrito aquí para Barcelona.

A. Carga y estructura del dataset

El fichero de origen trae **15.293 filas y 90 columnas**: 42 float64, 30 object y 18 int64. Dos cosas llaman la atención de inmediato: `price` llega como texto ("409.00", con símbolo de moneda y separador de miles) en vez de numérico, y hay columnas float64 cuyo nombre sugiere texto o fecha (`host_since`, `host_response_time`). Resultan ser parte de un bloque de **12 columnas completamente vacías** (100% nulas): `neighbourhood`, `host_acceptance_rate`, `host_response_time`, `host_thumbnail_url`, `host_neighbourhood`, `host_total_listings_count`, `host_verifications`, `host_since`, `host_response_rate`, `instant_bookable`, `neighborhood_overview`, `calendar_updated`. De las 90 columnas, solo 78 tienen algún dato real en este snapshot.

También aparece un grupo de cinco columnas no estándar de Inside Airbnb, `price_quote_*` (`price_quote_total_price`, `price_quote_price_per_night`, fechas de check-in/check-out, JSON de la cotización): parecen una cotización para unas fechas concretas, no el precio base del anuncio. Su destino se decide más adelante, al analizar `price` a fondo (Sección 3.1 de la memoria).

B. Corrección de tipos

Cuatro ajustes antes de poder trabajar con las columnas: `price` se limpia de símbolo de moneda y separador de miles y se convierte a float; `last_scraped`, `first_review`, `last_review` y `calendar_last_scraped` pasan de texto a datetime (`host_since` se deja fuera, es una de las 12 columnas vacías); los flags de texto "t"/"f" (`host_is_superhost`, `host_has_profile_pic`, `host_identity_verified`, `has_availability`) se mapean a boolean nullable; y `host_profile_id`, inferido como float64 por tener 87 nulos, se pasa a Int64 (entero nullable).

C. Tratamiento de nulos

Con 90 columnas hay muchos más nulos que en un dataset resumido. Cada grupo se trata según su causa, no con una regla única:

Grupo de columnas	Tratamiento y motivo
-------------------	----------------------

12 columnas 100% vacías	Se eliminan: no aportan ninguna información. El dataset pasa de 90 a 78 columnas.
bathrooms (23,3% nulo, 3.565 filas)	Se recupera desde bathrooms_text (solo 0,09% nulo), extrayendo el número con una expresión regular y mapeando "half-bath" a 0,5. Se recuperan 3.556 de 3.565 valores (99,7%), en vez de imputar o descartar filas.
Reviews (reviews_per_month, first_review/last_review, review_scores_*, ~23% nulo)	Se confirma que el nulo coincide al 100% con number_of_reviews == 0 (alojamiento sin reseñas todavía). reviews_per_month se imputa a 0 (valor real). El resto se deja como NaN/NaT genuino: inventar una puntuación sería el peor tipo de dato falso posible.
license (19,9% nulo)	El nulo se interpreta como "sin licencia registrada": se guarda como flag has_license antes de imputar el texto a "Sin licencia".
price (12,67% nulo, 1.938 filas)	Variable objetivo: no se imputa, se descartan las filas sin precio.
13 columnas de bajo volumen (host, estancia; ~1,16% del dataset)	Identificadores y metadatos de cuenta con muy pocas filas afectadas: no compensa imputarlos, se descartan las filas.
bedrooms (11,56% nulo) / beds (5,23% nulo)	El nulo no es aleatorio: se concentra en Private room (41,2%) y Shared room (12,4%) frente a Entire home/apt (2,8%). Se imputa con la mediana de cada variable dentro de cada room_type , no con una mediana global.
has_availability	Tras los descartes anteriores queda con un único valor (True en el 100% de las filas): ya no distingue nada, se elimina.
host_about, host_location, description (texto libre)	Se dejan tal cual: un nulo en texto libre no bloquea nada.

Tras toda la limpieza, el dataset de Barcelona queda con **13.258 filas y 78 columnas** (de las 15.293 filas y 90 columnas de origen).

D. Duplicados

0 filas duplicadas de fila completa, 0 id repetidos, y 0 filas idénticas en todo salvo id: no hay ningún duplicado que eliminar. Sí aparecen 221 filas (83 grupos) que comparten name, host_name, latitude y longitude — "duplicados lógicos" del mismo edificio o del mismo anfitrión, pero con datos propios en el resto de columnas (reviews, disponibilidad, licencia): son anuncios reales distintos, no se tocan.

E. Variables categóricas

Con 79 columnas hace falta algo más que "identificador" vs. "categórica". Se distinguen cuatro grupos: **URLs** (listing_url, picture_url...), con cardinalidad casi igual al número de filas y cero valor analítico; **cuasi-identificadores de texto libre** (name, description, host_about, amenities, license), diferidos a feature engineering; bathrooms_text, ya explotada en la Sección C; y las **categóricas reales de baja cardinalidad**, las únicas que se analizan aquí:

Variable	Distribución
room_type (4 categorías)	Entire home/apt domina (10.107, 76,2%), Private room 2.996 (22,6%), Shared room y Hotel room casi residuales (97 y 58).
property_type (47 categorías)	Dominado por Entire rental unit (69%) y Private room in rental unit (16%); el resto es cola larga de categorías con poca muestra (hoteles, hostales, lofts). Necesitará agrupación de categorías raras si se usa como feature.
neighbourhood_group_cleansed (10 distritos)	Eixample (5.170) y Ciutat Vella (2.757) concentran la mayoría; Nou Barris (141) y Sant Andreu (180) son los más pequeños.
source (2 categorías)	96,2% city scrape / 3,8% previous scrape: metadato de cómo se recolectó el anuncio, sin relación esperable con price.
Booleanos: host_has_profile_pic, host_identity_verified	97,8% y 96,5% a True: poca variabilidad, aportarán poco como predictoras.
host_is_superhost (27,8% True) / has_license (86,6% True)	Más equilibradas, con potencial real de señal (se confirma en la Sección H).

F. Variables numéricas: estadísticos y asimetría

De las 49 columnas numéricas, tras descartar identificadores y agrupar familias redundantes (estancia: minimum_nights/minimum_minimum_nights correlacionan 1,00 entre sí, literalmente el mismo dato; disponibilidad: availability_30 a _365, solape moderado 0,34–0,90), el análisis se centra en 14 variables clave. Casi todas muestran asimetría positiva fuerte (number_of_reviews_ltm 14,97, reviews_per_month 13,69, beds 11,57, price 9,02); review_scores_rating es la única con asimetría **negativa** fuerte (–3,74): la mayoría puntúa muy alto, cerca de 5, y son los pocos malos los que estiran la cola hacia abajo.




Figura A1. Distribución de las 14 variables numéricas clave de Barcelona.

G. Outliers

Con el método de rango intercuartílico (IQR), `calculated_host_listings_count` (18,7%) y `number_of_reviews` (10,6%) encabezan la proporción de valores extremos, seguidos de `price` (4,4%). Es nuevo el caso de `review_scores_rating` (3,6%): al concentrarse casi todas las notas cerca de 5, el IQR marca como "outlier" cualquier puntuación algo más baja, la otra cara de su asimetría negativa.




Figura A2. Diagramas de caja de las 14 variables numéricas clave de Barcelona.

El caso más investigado a fondo es beds (máximo 127) y bedrooms (máximo 29). Casi todos los valores altos son "Group Flats" reales: pisos de 16–26 dormitorios, capacidad para 16 personas (el máximo de accommodates en Airbnb) y precios de 1.800–3.700€/noche, consistentes entre sí. Hay una única excepción real: un anuncio con beds=127 pero solo 2 bedrooms y accommodates=4, inconsistente con el resto de la fila — un error de captura genuino, corregido con la misma regla que un nulo (mediana de beds por room_type). Con esa única excepción corregida, **no se recorta ningún otro outlier por IQR**: precios altos, muchas reseñas o Group Flats son variabilidad real del mercado.

H. Relación con el precio (análisis bivalente)

Por barrio, Eixample es el más caro por media (309,57€); Ciutat Vella baja mucho por mediana (114,12€ frente a una media de 190,95€), efecto de los pisos de lujo del centro histórico que inflan la media. Por tipo, Entire home/apt (284,80€ de media) está muy por encima de Private room (97,36€) y Shared room (73,97€).

Las variables de **tamaño** son, con diferencia, las más relacionadas con el precio de todo el proyecto: bedrooms (Pearson 0,66), accommodates (0,65), beds (0,62) y bathrooms (0,59). La relación bedrooms→price es casi monótona: 1 dormitorio ≈ 98€ de mediana, 2 ≈ 210€, 3 ≈ 279€... hasta los Group Flats de 9+ dormitorios, ≈1.800€.




Figura A3. Precio por número de dormitorios (limitado a ≤ 6 para que los Group Flats no aplasten la escala).

has_license muestra una diferencia grande (mediana 203€ con licencia vs. 73€ sin ella), que se mantiene dentro de cada room_type (p. ej. Entire home/apt: 234€ vs. 103€), así que no es solo un efecto de tipo de alojamiento. host_is_superhost pesa mucho menos (220€ vs. 161€ de mediana, pero correlación real casi nula, 0,004: la comparación de dos medianas exageraba el efecto). review_scores_rating sorprende por no aportar casi nada (correlación 0,08): casi todo el mundo puntúa alto, la nota apenas distingue entre anuncios. Por property_type, Entire serviced apartment es el más caro por mediana (282€), por delante incluso de Entire rental unit (221€).

I. Correlación multivariante

La correlación de Pearson asume una relación lineal, pero varias variables (reviews, minimum_nights) tienen colas largas, así que conviene compararla con Spearman:

Variable	Pearson	Spearman
bedrooms	0,66	0,55
accommodates	0,65	0,69
beds	0,62	0,61
bathrooms	0,59	0,28
estimated_revenue_l365d	0,20	0,49
number_of_reviews	0,05	0,43
has_license	0,15	0,35

minimum_nights	-0,33	-0,65
host_is_superhost	0,004	0,13

Las variables de tamaño se mantienen arriba con ambos métodos; las de reviews solo destacan con Spearman (señal mucho más robusta que Pearson sobre el precio en bruto). El heatmap confirma además que accommodates/bedrooms/beds/bathrooms están muy correlacionadas entre sí (0,80–0,84), un aviso de multicolinealidad para un modelo lineal (Sección 3.3 de la memoria).




Figura A4. Matriz de correlación (Spearman) de las variables numéricas y flags booleanos con price.




Figura A5. Relación entre price (en log1p), bedrooms y accommodates. La línea vertical marca accommodates=16, el máximo permitido en Airbnb; la esquina superior derecha aísla a los Group Flats.

J. Análisis geográfico

El rango de coordenadas es coherente con Barcelona (latitud 41,35–41,46, longitud 2,09–2,22). Los distritos forman regiones geográficas compactas y reconocibles, lo que confirma que neighbourhood_group_cleansed está bien asignado, y el precio es visiblemente más alto hacia el centro.




Figura A6. Anuncios de Barcelona por distrito.




Figura A7. Precio ($\log_{1p}$) por ubicación geográfica.

El 75% de los Group Flats (59 de 79 anuncios con 10+ dormitorios) se concentra en Eixample, que tiene los edificios de ensanche con plantas grandes, aptas para convertir en pisos de varias habitaciones. Como complemento a la distancia al centro, se cuenta también cuántos anuncios hay en un radio de 150 metros alrededor de cada uno (con BallTree y distancia haversine): media de ~55, con correlación positiva pero modesta con el precio (0,12), consistente con que las zonas más densas en Airbnb coinciden con las más céntricas y caras, sin un "descuento por competencia" visible a este nivel.

K. Amenities

amenities llega como una lista en formato JSON, sin nulos, con una media de ~30 elementos por anuncio. Parseándola aparecen **2.337 valores distintos**, y más de la mitad (57%) aparece en un único anuncio: una cola larguísima de variantes hiperespecíficas (marcas, modelos, velocidades de wifi) que hace inviable un *one-hot* directo. Además, un mismo concepto se escribe de varias formas: el aire acondicionado aparece como "Air conditioning" (8.682), "AC - split type ductless system" (1.362), "Central air conditioning" (1.139) y

"Portable air conditioning" (121), cuatro strings distintos para la misma idea.

Se prueban cuatro candidatas por palabra clave (agrupando variantes), para ver si alguna correlaciona con price lo suficiente como para justificarla:

Candidata	Prevalencia	Correlación con price
n_amenities (recuento total)	media 29,7	0,163
has_dishwasher	47,6%	0,155
has_ac	84,8%	0,144
has_pool	3,7%	0,036

Las tres primeras correlacionan 0,14–0,16, señal real pero modesta, del mismo orden que distance_to_center_km. has_pool sale más débil, pero se mantiene igual que review_scores_rating en la Sección H: una correlación débil no descarta una variable, solo baja las expectativas. Las cuatro se construyen en 02_feature_engineering.ipynb.

L. Conclusiones del EDA de Barcelona

De las 15.293 filas y 90 columnas originales quedan **13.258 filas × 78 columnas**. El hallazgo principal es que **el tamaño manda**: bedrooms, accommodates, beds y bathrooms son, con diferencia, las variables más correlacionadas con price de todo el proyecto, muy por delante de calculated_host_listings_count (0,21). Le sigue has_license, con un efecto grande y consistente. Dos sorpresas negativas: review_scores_rating apenas explica el precio, y host_is_superhost parece importar por comparación de medianas pero su correlación real es casi nula. De cara al modelado quedan diferidas varias decisiones: multicolinealidad entre variables de tamaño, agrupación de property_type (47 categorías), y las familias redundantes de estancia/disponibilidad, que se resuelven en 02_feature_engineering.ipynb (Sección 3 de la memoria).

M. Diferencias por ciudad respecto a Barcelona

Todo lo anterior (secciones A a L) describe el EDA de Barcelona. Las otras 6 ciudades siguen el mismo recorrido notebook a notebook, pero cada una tiene su propia historia: artefactos de datos distintos, hallazgos geográficos propios y matices en qué variable correlaciona más con el precio. Esta sección recoge, ciudad a ciudad, en qué se aparta cada una de lo descrito para Barcelona; lo que no se menciona es porque coincide con Barcelona.

Ciudad	Diferencias respecto a Barcelona
--------	----------------------------------

Madrid	22.708 filas de origen → 18.949 tras la limpieza. Dos artefactos de datos que no aparecían en Barcelona: 32 anuncios con "precio de bloqueo" por host (3 hosts, mismo precio repetido en todos sus anuncios, sin reseñas) y 40 más con precio de bloqueo individual (>500€ por plaza y noche, sin reserva ni reseña reciente), ambos eliminados. La correlación de Pearson entre tamaño y precio es mucho menos fiable aquí (0,19–0,33 en bruto) que con Spearman o $\log(\text{price})$ (0,49–0,65, similar a Barcelona): para cualquier análisis de importancia en Madrid conviene usar Spearman, no Pearson sobre precio en crudo. Concentración geográfica más fuerte (Centro agrupa el 42% de los anuncios) y los pisos grandes no se concentran en un distrito concreto, a diferencia del 75% en Eixample de Barcelona.
Valencia	7.851 filas de origen → 7.234 tras la limpieza. Primer artefacto de "precio disuasorio" del proyecto: 20 anuncios a 9.900€ o 3.000€ exactos, 19 de ellos del mismo anfitrión (un camping con varios bungalows), eliminados por no ser precio de mercado real. Al quitarlos, la correlación de <code>accommodates</code> con <code>price</code> sube de 0,23 a 0,35 en Pearson. Patrón de tamaño más débil que Barcelona y con más diferencia entre métodos (<code>accommodates</code>: Pearson 0,35 frente a Spearman 0,63), señal de una cola de precio más marcada. <code>has_pool</code> tiene más potencial que en Barcelona.
Málaga	9.568 filas de origen. Mismo patrón de precio disuasorio que Valencia, pero como 2 valores únicos y aislados (112.070€ y 11.991€, de hosts distintos), no un cluster de un solo host: al quitarlos, <code>accommodates</code> pasa de 0,07 a 0,52 de Pearson, el salto más grande de las 7 ciudades. Sin <code>neighbourhood_group_cleaned</code>: <code>neighbourhood_cleaned</code> (11 valores, Centro con el 67,5%) hace de distrito y de barrio a la vez, así que no hace falta el <i>target encoding</i> de barrio usado en Barcelona. Hallazgo propio: <code>has_pool</code> correlaciona 0,229 con <code>price</code> pese a solo un 8,8% de prevalencia, la señal de amenities más fuerte de las 7 ciudades hasta Euskadi.

Sevilla	8.245 filas de origen → 7.640 tras la limpieza. A diferencia de Valencia y Málaga, no hay un artefacto de precio disuasorio limpio: la cola alta baja de forma continua desde el palacio genuino más caro (10.970€) hasta indicios sueltos ("Rent it if you can afford it!", 8.052€) sin frontera objetiva, así que no se descarta ninguna fila por este motivo. El patrón de tamaño es el más ruidoso de las 7 ciudades (accommodates Spearman 0,50 pero Pearson solo 0,22): ni has_license (94,4% de prevalencia, casi sin variación) ni host_is_superuser aportan señal apreciable.
Mallorca	14.817 filas de origen, con la mayor proporción de filas sin price de las 7 ciudades (25,4%). Sin artefactos de precio que limpiar. Mismo caso que Málaga en geografía (sin neighbourhood_group_cleansed), pero aquí neighbourhood_cleansed llega a 53 municipios. La isla invierte la lógica centro-periferia: Palma, la capital, está entre los municipios más baratos (mediana 262€), mientras que pueblos pequeños del interior o de costa exclusiva (Marratxí, Deyá, Esporles, Andratx) encabezan el ranking. El precio depende sobre todo del tipo de propiedad (Entire villa/Entire home suman el 59,3%) y del tamaño, no de la centralidad. Mercado mucho más profesionalizado (mediana de 10 anuncios por anfitrión, frente a un dígito en el resto). has_license casi constante (99,6% True), poca utilidad predictiva esperable. Introduce has_sea_view junto a has_pool (70% de prevalencia).

Euskadi	6.248 filas de origen → 5.670 tras la limpieza (9,15% descartado por price nulo). Requiere una corrección adicional que no aparece en ninguna otra ciudad: mojobake en los nombres de municipio y de provincia (20 de 207 municipios afectados). Donostia-San Sebastián (mediana 331€) casi duplica a Bilbao (168€) con un volumen casi idéntico de anuncios (1.410 vs. 1.492); Vitoria-Gasteiz, la capital autonómica, es la más barata de las tres (132,5€), prueba de que ser capital política no implica ser destino turístico caro. Hallazgo puntual único del proyecto: 12 anuncios en Bilbao renombrados explícitamente para la semana de la final de la Europa League 2026 en San Mamés, con mediana de precio (405€) más del doble de la general y picos de hasta 4.222€/noche — un pico de demanda real y verificable, no un error. has_dishwasher (49,7% de prevalencia, correlación 0,197) es la amenity candidata más fuerte de las 7 ciudades, y property_type llega a 61 categorías, la cifra más alta del proyecto.
---------	---