

Anexo I

Glosario de variables

FairNight: un sistema de recomendación de precios para anuncios de Airbnb

Trabajo Fin de Máster, Modalidad Semipresencial
Yago Coll Crespo, Septiembre 2026

Glosario de variables: de las 90 columnas del origen a las que usa el modelo

Este anexo recoge, agrupadas por bloque temático, las 90 columnas que trae el fichero `listings.csv.gz` de Inside Airbnb, con una definición breve de cada una y qué se hizo con ella: si se mantiene tal cual, si se transforma en otra variable, o si se descarta (y por qué). **Todo el glosario está construido sobre el pipeline de Barcelona** (descrito con más detalle en la Sección 3 de la memoria), tomada como referencia por ser la ciudad con el proceso más documentado. Las otras 6 ciudades parten de los mismos 90 campos y aplican el mismo criterio, pero no todas terminan con exactamente el mismo conjunto de variables: la última sección de este anexo recoge, ciudad a ciudad, en qué se aparta cada una de lo descrito aquí para Barcelona.

Cómo leer la columna "Qué se hizo con ella": "Se mantiene" significa que la variable (o una transformación directa suya, como su logaritmo) entra tal cual al modelo final de 71 columnas de la Sección 3.7. "Se transforma en X" significa que no sobrevive con su propio nombre, pero su información sí entra al modelo dentro de otra variable. "Se descarta" significa que no se usa en absoluto. Un nombre terminado en asterisco, como `district_*`, no es una única columna sino una familia entera: representa todas las columnas *one-hot* que empiezan por ese prefijo, una por cada categoría (por ejemplo, `district_Eixample`, `district_Retiro`, etc.).

A. Identificadores y metadatos de scraping

Variable	Qué se hizo con ella
<code>id</code> : identificador único del anuncio.	Se mantiene como identificador de referencia (no es una feature: no describe el alojamiento).
<code>listing_url</code> : URL pública del anuncio.	Se descarta.
<code>scrape_id</code> : identificador interno de la sesión de scraping de Inside Airbnb.	Se descarta.
<code>last_scraped</code> : fecha en la que se capturó ese anuncio concreto.	Se descarta como feature; se usa solo para fijar la fecha del snapshot de cada ciudad (Sección 1.4 de la memoria).
<code>source</code> : cómo se encontró el anuncio en el rastreo (búsqueda por ciudad o por vecindario).	Se descarta.
<code>host_id</code> : identificador único del anfitrión.	Se mantiene como identificador de referencia (no feature).
<code>host_url</code> : URL del perfil del anfitrión.	Se descarta.
<code>host_profile_id</code> : identificador del perfil del anfitrión, distinto de <code>host_id</code> en este snapshot.	Se mantiene como identificador de referencia (no feature).

host_profile_url: URL del perfil del anfitrión (duplica host_url).	Se descarta.
picture_url: URL de la foto principal del anuncio.	Se descarta.
host_thumbnail_url: URL de la miniatura de perfil del anfitrión.	Se descarta (columna vacía en el snapshot).
host_picture_url: URL de la foto de perfil del anfitrión.	Se descarta (columna vacía en el snapshot).
calendar_updated: fecha de la última actualización del calendario.	Se descarta (columna vacía en el snapshot).
calendar_last_scraped: fecha en la que se capturó el calendario de disponibilidad.	Se descarta.

B. Texto libre del anuncio y del anfitrión

Variable	Qué se hizo con ella
name: título del anuncio, escrito por el anfitrión.	Se descarta: es texto de marketing, no una descripción objetiva del alojamiento.
description: descripción larga del anuncio.	Se descarta por el mismo motivo.
neighborhood_overview: descripción del barrio, escrita por el anfitrión.	Se descarta (columna vacía en el snapshot).
host_name: nombre del anfitrión.	Se descarta.
host_about: biografía del anfitrión.	Se descarta: redundante con las señales de host que ya se capturan de forma estructurada (antigüedad, tamaño de portfolio, Superhost).
host_location: ciudad de residencia declarada por el anfitrión.	Se descarta por el mismo motivo.

C. El anfitrión

Variable	Qué se hizo con ella
host_since: fecha de alta del anfitrión en Airbnb.	Se descarta (columna vacía en el snapshot).
hosts_time_as_user_years: años como usuario de Airbnb (huésped o anfitrión).	Se transforma, junto con la siguiente, en host_user_tenure_years (no entra al modelo final, se calculó por coherencia con la de abajo).
hosts_time_as_user_months: meses (resto) como usuario de Airbnb.	Igual que la anterior.

hosts_time_as_host_years: años como anfitrión.	Se transforma, junto con la siguiente, en host_tenure_years (esta sí se mantiene como feature del modelo).
hosts_time_as_host_months: meses (resto) como anfitrión.	Igual que la anterior.
host_response_time: rapidez media de respuesta del anfitrión.	Se descarta (columna vacía en el snapshot).
host_response_rate: % de mensajes que responde el anfitrión.	Se descarta (columna vacía en el snapshot).
host_acceptance_rate: % de solicitudes que acepta el anfitrión.	Se descarta (columna vacía en el snapshot).
host_is_superhost: si el anfitrión tiene el distintivo "Superhost".	Se mantiene tal cual.
host_neighbourhood: barrio de residencia declarado por el anfitrión.	Se descarta (columna vacía en el snapshot).
host_listings_count: nº de anuncios que el propio anfitrión declara tener.	Se descarta: redundante con calculated_host_listings_count, que Inside Airbnb recalcula a partir del scraping real y es más fiable.
host_total_listings_count: variante del anterior.	Se descarta (columna vacía en el snapshot).
host_verifications: lista de verificaciones de identidad del anfitrión (email, teléfono...).	Se descarta (columna vacía en el snapshot).
host_has_profile_pic: si el anfitrión tiene foto de perfil.	Se mantiene tal cual.
host_identity_verified: si el anfitrión verificó su identidad.	Se mantiene tal cual.

D. Ubicación

Variable	Qué se hizo con ella
neighbourhood: barrio declarado por el anfitrión, en texto libre y sin normalizar.	Se descarta (columna vacía en el snapshot).
neighbourhood_cleaned: barrio normalizado por Inside Airbnb contra el callejero oficial.	Se transforma en neighbourhood_price_encoded (Sección 3.4 de la memoria), la variable que sí entra al modelo; el texto original se descarta después.

neighbourhood_group_cleansed: distrito normalizado.	Se mantiene, codificada con <i>one-hot</i> (district_*). Ausente en los datos de Málaga (Sección 3.6 de la memoria).
latitude: latitud del anuncio.	Se mantiene tal cual, y además es la base de distance_to_center_km y n_nearby_150m.
longitude: longitud del anuncio.	Igual que la anterior.

E. Alojamiento: tipo y tamaño

Variable	Qué se hizo con ella
property_type: tipo de propiedad detallado (por ejemplo, "Entire rental unit").	Se transforma: las categorías raras se agrupan en "Other" y el resultado se codifica con <i>one-hot</i> (property_type_*).
room_type: tipo de alojamiento a alto nivel (vivienda entera, habitación privada, compartida u hotel).	Se mantiene, codificada con <i>one-hot</i> (room_type_*).
accommodates: nº máximo de huéspedes.	Se mantiene tal cual.
bathrooms: nº de baños (numérico).	Se mantiene tal cual, más su versión bathrooms_log.
bathrooms_text: nº de baños en texto libre (por ejemplo, "1.5 baths").	Se usa para recuperar bathrooms cuando falta; el texto se descarta después.
bedrooms: nº de dormitorios.	Se mantiene tal cual, más su versión bedrooms_log.
beds: nº de camas.	Se mantiene tal cual, más su versión beds_log.
amenities: lista de comodidades del anuncio, en texto.	Se transforma en 4 variables (has_ac, has_pool, has_dishwasher, n_amenities); el texto original se descarta.

F. Precio y cotización

Variable	Qué se hizo con ella
price: precio por noche publicado.	Es la variable objetivo del modelo (no una feature).
price_quote_checkin_date: fecha de entrada usada para pedir una cotización de ejemplo durante el scraping.	Se descarta.
price_quote_checkout_date: fecha de salida de esa cotización.	Se descarta.

price_quote_total_price: precio total de esa cotización.	Se descarta: coincide con price recalculado, sería fuga de información.
price_quote_price_per_night: precio por noche de esa cotización.	Se descarta por el mismo motivo: coincide de forma exacta con price.
price_quote_raw: JSON completo de la cotización consultada.	Se descarta como feature; se usó puntualmente en el EDA para diagnosticar los precios disuasorios (Sección 2.4 de la memoria).

G. Condiciones de estancia

Variable	Qué se hizo con ella
minimum_nights: estancia mínima exigida, en noches.	Se mantiene tal cual; es la variable más importante del modelo (Sección 5 de la memoria).
maximum_nights: estancia máxima permitida.	Se mantiene tal cual.
minimum_minimum_nights: estancia mínima más baja fijada en el calendario.	Se descarta: correlaciona 1,00 con minimum_nights, es el mismo dato.
maximum_minimum_nights: estancia mínima más alta fijada en el calendario.	Se descarta por la misma redundancia.
minimum_maximum_nights: estancia máxima más baja fijada en el calendario.	Se descarta por la misma redundancia.
maximum_maximum_nights: estancia máxima más alta fijada en el calendario.	Se descarta por la misma redundancia.
minimum_nights_avg_ntm: estancia mínima media de los próximos meses.	Se descarta por la misma redundancia.
maximum_nights_avg_ntm: estancia máxima media de los próximos meses.	Se descarta por la misma redundancia.

H. Disponibilidad

Variable	Qué se hizo con ella
has_availability: si el anuncio tenía disponibilidad en el momento del scraping.	Se descarta: queda constante tras el resto de la limpieza.
availability_30: noches libres en los próximos 30 días.	Se descarta por redundancia con availability_365.
availability_60: noches libres en los próximos 60 días.	Se descarta por la misma redundancia.

availability_90: noches libres en los próximos 90 días.	Se descarta por la misma redundancia.
availability_365: noches libres en el próximo año.	Se mantiene, como referencia única de disponibilidad.
availability_eoy: noches libres hasta fin de año natural.	Se descarta por la misma redundancia.

I. Reseñas y ocupación

Variable	Qué se hizo con ella
number_of_reviews: nº total de reseñas históricas.	Se mantiene tal cual, más su versión number_of_reviews_log.
number_of_reviews_ltm: reseñas en los últimos 12 meses.	Se mantiene tal cual, más su versión log.
number_of_reviews_l30d: reseñas en los últimos 30 días.	Se descarta: ventana demasiado fina, redundante con las anteriores.
number_of_reviews_ly: reseñas del año natural anterior.	Se descarta por el mismo motivo.
estimated_occupancy_l365d: ocupación estimada por Inside Airbnb en el último año.	Se mantiene tal cual.
estimated_revenue_l365d: ingresos estimados en el último año.	Se descarta: se calcula como price × ocupación, así que usarla sería fuga de información directa (Sección 3.1 de la memoria).
first_review: fecha de la primera reseña.	Se transforma en listing_age_days (antigüedad del anuncio); la fecha original se descarta.
last_review: fecha de la última reseña.	Se transforma en days_since_last_review; la fecha original se descarta.
review_scores_rating: valoración media general (escala 0-5).	Se mantiene tal cual, sin imputar los NaN de anuncios sin reseñas.
review_scores_accuracy: valoración de precisión de la descripción.	Se descarta: correlaciona 0,59-0,86 con review_scores_rating, el mismo tipo de señal.
review_scores_cleanliness: valoración de limpieza.	Se descarta por el mismo motivo.
review_scores_checkin: valoración del proceso de entrada.	Se descarta por el mismo motivo.

review_scores_communication: valoración de la comunicación con el anfitrión.	Se descarta por el mismo motivo.
review_scores_location: valoración de la ubicación.	Se descarta por el mismo motivo.
review_scores_value: valoración de relación calidad-precio.	Se descarta por el mismo motivo.
reviews_per_month: ritmo medio de reseñas por mes.	Se mantiene tal cual, más su versión log; imputado a 0 en anuncios sin reseñas.

J. Normativa y reservas

Variable	Qué se hizo con ella
license: nº de licencia turística (texto), o su ausencia.	Se transforma en el flag has_license (mantenido); el texto original se descarta.
instant_bookable: si se puede reservar sin aprobación del anfitrión.	Se descarta (columna vacía en el snapshot).

K. Actividad del anfitrión en otros anuncios

Variable	Qué se hizo con ella
calculated_host_listings_count: nº de anuncios que Inside Airbnb atribuye a ese anfitrión (recuento propio a partir del scraping, más fiable que el autodeclarado).	Se mantiene tal cual, más su versión log; también es la base de la variable categórica de tamaño de portfolio (host_size_*).
Las tres variantes de calculated_host_listings_count por tipo (_entire_homes, _private_rooms, _shared_rooms): de esos anuncios, cuántos son vivienda entera, habitación privada u habitación compartida, respectivamente.	Se combinan las tres en host_entire_homes_ratio (mantenida); el desglose original se descarta.

L. Diferencias por ciudad respecto a Barcelona

Todo lo anterior (secciones A a K) describe el pipeline construido sobre Barcelona. Las otras 6 ciudades parten de los mismos 90 campos y aplican el mismo criterio de limpieza y transformación, columna por columna, pero el resultado final no es idéntico en las siete: algunas variables cambian de granularidad, alguna llega vacía donde en Barcelona no lo estaba, y en dos ciudades se sustituye o se añade alguna variable de comodidades. Esta tabla recoge, ciudad a ciudad, en qué se aparta cada una de lo descrito para Barcelona; lo que no se menciona en una fila es porque coincide con Barcelona.

Ciudad	Diferencias respecto a Barcelona
Madrid	Mismo conjunto de variables que Barcelona. Cambia solo la granularidad de las categóricas: 21 distritos en <code>district_*</code> (frente a 10) y 20 categorías en <code>property_type_*</code> tras agrupar (frente a 14).
Valencia	Mismo conjunto de variables. 19 distritos en <code>district_*</code> y 15 categorías en <code>property_type_*</code> .
Málaga	<code>neighbourhood_group_cleansed</code> (distrito) llega completamente vacía en el fichero de origen (Sección 3.6 de la memoria): "distrito" cae sobre el mismo nivel que barrio, así que los 11 valores de <code>district_*</code> son en realidad sus 11 barrios, no distritos administrativos. 16 categorías en <code>property_type_*</code> .
Sevilla	Mismo conjunto de variables que Barcelona. 11 distritos en <code>district_*</code> y 13 categorías en <code>property_type_*</code> , la cardinalidad más baja de las 7 ciudades.
Mallorca	Mismo caso que Málaga: <code>neighbourhood_group_cleansed</code> llega vacía y "distrito" cae sobre <code>neighbourhood_cleansed</code> , aquí a nivel de municipio: 53 valores en <code>district_*</code> , la granularidad geográfica más fina de las 7 ciudades. Su <code>room_type</code> no tiene ninguna categoría "Shared room" en los datos (3 categorías en vez de 4). En comodidades, sustituye <code>has_dishwasher</code> por <code>has_sea_view</code> : en un mercado insular dominado por villas, el lavavajillas no distingue nada y la vista al mar sí.
Euskadi	Mismo conjunto base de variables, con una añadida: conserva <code>has_dishwasher</code> y además incorpora <code>has_sea_view</code> (litoral de Donostia a Bilbao), la única de las 7 ciudades con 5 variables de comodidades en vez de 4. Solo 3 valores en <code>district_*</code> (Bilbao, Donostia y Vitoria), la granularidad más gruesa del proyecto, frente a los 10-53 del resto.